

目录

1	实验介绍	2
1.1	实验内容	2
1.2	实验环境	2
2	实验过程	3
2.1	SIFT 图像特征提取原理	3
2.2	尺度空间极值点检测	3
2.3	关键点精确定位	3
2.4	关键点方向确定	3
2.5	关键点描述子生成	5
2.6	相似图片匹配	6
3	实验结果	9
4	总结与分析	10

1 实验介绍

1.1 实验内容

在 dataset 文件夹中的所有图片中搜索 target.jpg 图片所示物体, 并绘制程序认为的好的匹配.

1.2 实验环境

操作系统: Ubuntu 18.04 LTS

Python 版本: 3.7

NumPy: 1.14.5

OpenCV-Python: 3.4.3.18

2 实验过程

2.1 SIFT 图像特征提取原理

尺度不变特征变换 (Scale-Invariant Feature Transform, SIFT), 是计算机视觉领域的一种图像特征检测算法, 用于检测并描述图像的局部特征. 该算法于 1999 年由 David Lowe 提出, 并广泛应用于计算机视觉的诸多领域.

SIFT 算法基于图像的局部特征, 可以很好地处理图像的匹配问题, 具有如下特点:

1. SIFT 特征是图像的局部特征, 其对旋转、尺度缩放、亮度变化保持不变性, 对视角变化、仿射变换、噪声也保持一定程度的稳定性;
2. 独特性好, 信息量丰富, 适用于在海量特征数据库中进行快速、准确的匹配;
3. 多量性, 即使少数的几个物体也可以产生大量的 SIFT 特征向量;
4. 高速性, 经优化的 SIFT 匹配算法甚至可以达到实时的要求;
5. 可扩展性, 可以很方便的与其他形式的特征向量进行联合.

SIFT 图像特征提取有 4 个基本步骤, 分别为:

1. 尺度空间极值点检测
2. 关键点精确定位
3. 关键点方向确定
4. 关键点描述子生成

2.2 尺度空间极值点检测

此步骤中, 对图像建立了尺度空间, 实现时使用高斯差分金字塔来表示, 然后寻找高斯差分 (DoG) 空间中的局部极值点.

由于本次实验并未深入此步骤, 故在此略去具体实现细节.

2.3 关键点精确定位

上一步中所检测到的极值点是离散空间的极值点, 并不是真正的极值点, 因而需要在这一步骤中进行更加精确的定位. 根据 SIFT 算法的原理, 需要对尺度空间的 DoG 函数进行曲线拟合 (利用其在尺度空间的 Taylor 展开式); 同时, 还需要进一步消除位于边缘处的关键点 (利用关键点处的 Hessian 矩阵).

同样地, 本次实验并未深入于此, 故在此略过.

2.4 关键点方向确定

在经过前两个步骤的处理后, 我们得到了图像中一定数量的关键点坐标.

当然, 需要说明的是, 本次实验中简便起见, 我们调用 OpenCV 提供的函数, 直接获取图像中的 Shi-Tomasi 角点. Shi-Tomasi 角点检测算法, 是 J. Shi 和 C. Tomasi 于 1994 年所提出的一种对 Harris 角点检测算子的改进.

```
1 img = cv2.imread(image_path)
2 img = rgb_to_grayscale(img)
3 shi_tomasi_corners = cv2.goodFeaturesToTrack(img, maxCorners=50,
  ↪ qualityLevel=0.01, minDistance=10)
```

```

4 # reshape into (N,2)
5 shi_tomasi_corners = shi_tomasi_corners.reshape((-1, 2)).astype("int32")

```

那么,对于检测到的每一个关键点,我们计算其 16×16 邻域内像素点的梯度强度与方向.然后将 $0 - 2\pi$ 的范围等分为 36 个区间,统计这 16×16 个像素点的梯度方向分布 (以其梯度强度为权值).最终,我们选取权重最大的区间的中值作为该关键点的主方向.

在具体的编程实现中,为避免梯度的重复计算,同时简化代码,我采取了一次性计算整幅图像像素点梯度的方法.需要注意的是,使用 `np.arctan()` 函数计算得到的方向范围为 $-\pi/2 - \pi/2$, 为了得到 $0 - 2\pi$ 范围,需要根据梯度的 x, y 方向分量符号进行判断:

```

1 def compute_gradient(gradient_image):
2     img = gradient_image.copy().astype("int32")
3     gradient, direction = [np.zeros_like(img, dtype="float32"), ] * 2
4     width, height = img.shape
5     for i in range(width - 1): # just ignore pixels on the edge
6         for j in range(height - 1):
7             d_x = img[i+1, j] - img[i-1, j]
8             d_y = img[i, j+1] - img[i, j-1]
9             gradient[i][j] = np.sqrt(d_x * d_x + d_y * d_y)
10            direction[i][j] = np.arctan(d_y/(d_x + 1e-8)) # -pi/2 ~ pi/2
11            if(d_x < 0):
12                direction[i][j] += np.pi # -pi/2 ~ 3pi/2
13            if(direction[i][j] < 0):
14                direction[i][j] += 2 * np.pi
15    return gradient, direction

```

而在计算关键点的主方向时,需要考虑到关键点靠近图片边沿的特殊情形,避免选取的关键点邻域超出图像的有效范围:

```

1 def vote_for_direction(gradient_zone, direction_zone):
2     potential_directions = np.zeros((36,))
3     width, height = gradient_zone.shape
4     for i in range(0, width):
5         for j in range(0, height):
6             d = int(direction_zone[i][j] // (np.pi/18))
7             potential_directions[d] += gradient_zone[i][j]
8     direction = (np.argmax(potential_directions) + 0.5) * np.pi / 18
9     return direction
10 width, height = gradient.shape
11 x1, x2, y1, y2 = max(0, x-8), min(width, x+8), max(0, y-8), min(height, y+8)
12 main_direction = vote_for_direction(
13     gradient[x1:x2, y1:y2], direction[x1:x2, y1:y2])

```

2.5 关键点描述子生成

在得到关键点的主方向 θ_0 之后, SIFT 算法将其作为物体坐标系的 X 方向, 那么对于关键点 16×16 邻域范围内的所有像素点的梯度, 需要将其从原先的图像坐标系换算到物体坐标系中:

$$\theta'(x, y) = \theta(x, y) - \theta_0$$

这一步操作使得 SIFT 算法能够较好地处理图片的旋转变换, 具有旋转不变性.

然而, 在进行坐标系换算之后, 物体坐标系上的点对应的图像坐标系上的点坐标可能并不是整数, 因而需要插值处理, 在这里我采用了双线性插值法, 即:

$$\theta(x', y') = \theta(x, y)dx_2dy_2 + \theta(x+1, y)dx_1dy_2 + \theta(x, y+1)dx_2dy_1 + \theta(x+1, y+1)dx_1dy_1$$




图 1: 插值法

编程实现如下:

```
1 def get_gradient(gradient, x, y): # x,y might not be integers
2     x_low, x_high = int(x), int(x)+1
3     y_low, y_high = int(y), int(y)+1
4     result = gradient[x_low][y_low] * (x_high - x) * (y_high - y)
5     result += gradient[x_low][y_high] * (x_high - x) * (y - y_low)
6     result += gradient[x_high][y_low] * (x - x_low) * (y_high - y)
7     result += gradient[x_high][y_high] * (x - x_low) * (y - y_low)
8     return result
9
10 def get_adjusted_direction(direction, main_direction, x, y):
11     x_low, x_high = int(x), int(x)+1
```

```

11 y_low, y_high = int(y), int(y)+1
12 result = direction[x_low][y_low] * (x_high - x) * (y_high - y)
13 result += direction[x_low][y_high] * (x_high - x)*(y-y_low)
14 result += direction[x_high][y_low] * (x-x_low) * (y_high - y)
15 result += direction[x_high][y_high] * (x-x_low) * (y - y_low)
16 result -= main_direction
17 if result < 0:
18     result += 2*np.pi
19 return result

```

在获取了物体坐标系中 16×16 邻域所有点的梯度强度与方向之后, 则可据此生成该关键点的 SIFT 描述子: 将 16×16 的邻域均分成 4 个块, 每块有 4×4 个像素点. 而在每个块内, 类似于求主方向, 把 $0 - 2\pi$ 等分为 8 个区间, 统计梯度直方图, 从而得到维度为 8 的直方图向量. 因此, 对于每个关键点, 最终生成了 $4 \times 4 \times 8 = 128$ 维的 SIFT 描述子. 额外地, 在生成了描述子之后, 需要对其归一化处理, 以便后续的匹配.

```

1 def extract_features(gradient, direction): # both input size 16*16

2     def compute_histogram(x, y): # [x,x+3]*[y,y+3]
3         bins = np.zeros((8,))
4         for i in range(x, x+4):
5             for j in range(y, y+4):
6                 d = int(direction[i][j] // (np.pi/4))
7                 bins[d] += gradient[i][j]
8         return bins

9     assert gradient.shape == (16, 16), "Invalid shape!"
10    features = list()
11    for i in range(0, 13, 4):
12        for j in range(0, 13, 4):
13            features.append(compute_histogram(i, j))
14    features = np.array(features).reshape((-1,))
15    features = features / np.sqrt(np.sum(features * features))
16    return features

```

2.6 相似图片匹配

给定一张图片, 根据以上算法, 对其提取出 N 个 128 维 SIFT 描述子, 那么, 检测两张图片是否相似, 可以通过检测两者的 SIFT 描述子是否相似来初步实现.

对于两个 SIFT 描述子, 由于我们已经对其做过归一化处理, 那么比较其相似度, 只需计算二者在向量空间中的夹角大小, 或是直接计算二者的向量内积. 当二者的内积超过一定的阈值, 我们便认为二者成功匹配, 否则失败.

在编程实现中, 对于一个描述子, 先找到与其相似度最高的描述子, 匹配成功后将其置零, 以避免重复匹配. 同时将位于 `feature[1], target_feature[1]` 中的关键点坐标对保存. 图片匹配结束后, 返回匹配点个数 `score` 与匹配关键点坐标对.

```
1 def sift_match(target_feature, feature, threshold):
2     score = 0
3     result = list()
4     for i, descriptor in enumerate(target_feature[1]):
5         max_j, max_similarity = 0, 0
6         for j, x in enumerate(feature[1]):
7             if np.dot(descriptor, x) >= max_similarity:
8                 max_j, max_similarity = j, np.dot(descriptor, x)
9         if max_similarity >= threshold:
10             score += 1
11             feature[1][max_j] = np.zeros_like(feature[1][max_j])
12             result.append((target_feature[0][i], feature[0][max_j]))
13     return score, result
```

为了方便展示匹配结果, 在找到最佳匹配图片之后, 将其与目标图片并排列为一张新图片, 同时将匹配点用线段相连, 以便观察.

考虑到目标图片与最佳匹配图片的尺寸差异, 在合并二者时, 需要对其中尺寸较小者进行填充拓展 (使用 `cv2.copyMakeBorder()`), 使得二者高度相匹配. 然而, 这样做之后, 必须保存这两张图片的最左上角像素点在合并后图片的位置, 否则将无法定位图片的关键点.

```
1 def merge(img1, img2):
2     result = []
3     img1 = cv2.imread(img1)
4     img2 = cv2.imread(img2)
5     final_height = max(img1.shape[0], img2.shape[0])
6     padding = int((final_height - img1.shape[0]) // 2)
7     result.append(padding)
8     result.append(padding)
9     odd = 1 if padding * 2 != (final_height - img1.shape[0]) else 0
10    img1 = cv2.copyMakeBorder(img1, padding, padding+odd, padding, padding,
11                               ↪ cv2.BORDER_CONSTANT, value=[0, 0, 0])
12    padding = int((final_height - img2.shape[0]) // 2)
13    result.append(padding+img1.shape[1])
14    result.append(padding)
15    odd = 1 if padding * 2 != (final_height - img2.shape[0]) else 0
16    img2 = cv2.copyMakeBorder(img2, padding, padding+odd, padding, padding,
17                               ↪ cv2.BORDER_CONSTANT, value=[0, 0, 0])
18    result.append(np.hstack((img1, img2)))
19    return result
```

```

18 def link_matched_points(merged_img, x1, y1, x2, y2, match_result):
19     new_img = merged_img.copy()
20     cv2.circle(new_img, (x1, y1), 5, [0, 0, 255], -1)
21     cv2.circle(new_img, (x2, y2), 5, [0, 0, 255], -1)
22     for pair in match_result:
23         cv2.line(new_img, (int(x1+pair[0][0]), int(y1+pair[0][1])),
24             ↪ (int(x2+pair[1][0]), int(y2+pair[1][1])), [255, 0, 0], 2)
25     return new_img
26
27 x1, y1, x2, y2, merged_img = merge(target_image, possible_images[best_match])
28 final_img = link_matched_points(merged_img, x1, y1, x2, y2,
29     ↪ match_result[best_match][1])

```


3 实验结果

在经过尝试之后, 设定角点检测数为 50, SIFT 描述子匹配阈值为 0.6, 对 dataset 文件中的 5 张图片与 target.jpg 进行匹配, 实验结果如下: (图片后的数字代表图像中成功匹配的关键点个数)

```
1 dataset/1.jpg 9
2 dataset/2.jpg 13
3 dataset/3.jpg 17
4 dataset/4.jpg 11
5 dataset/5.jpg 12
6 The best match is: dataset/3.jpg
```

可见, 利用 SIFT 算法, 成功地从多张图片中找到了目标图像. 那么, 将最佳匹配图片与目标图片展示出来, 结果如图2所示.




图 2: 匹配结果

4 总结与分析

在本次实验中, 虽然并未对 SIFT 算法进行完整的实现, 但通过查阅资料, 加以实现 SIFT 算法生成描述子的部分, 我对 SIFT 算法有了较深入的理解. 同时, 在实验中, 遇到了诸多实现上的细节问题, 诸如邻域超出图片范围, 这些问题在仅仅通过查看对 SIFT 算法的粗略描述往往难以解决, 需要根据自己的理解加以解决并多次尝试.

事实上, 如果仔细观察两幅图片的匹配结果 (图2), 会发现其实有一定数量的错误匹配存在. 这些错误虽未影响最终的匹配结果, 但是也显出了我所实现的 SIFT 算法存在缺陷 (甚至是错误). 这些问题可能来源于我对一些细节的不当处理, 也有可能是检测参数与阈值设置不当……

总而言之, 实现完整的 SIFT 算法并不容易, 然而所幸的是, 在一般的应用场合, 我们可以直接调用 OpenCV 或是其他库包所提供的实现, 从而避开算法的繁冗细节.